

PROJET DATA LAKE

Data Lake Financier

Architecture, pipeline, API Gateway et resultats verifies

Equipe	Artemie Smogunov, Nathan Smadja-Tubiana et Patrice Ignongui
Theme	Finance uniquement
Module	Data Lakes & Data Integration - EFREI 2025-2026
Professeur	Yvann Vincent
Date	7 juillet 2026

Validation technique effectuee sur Docker, Airflow, FastAPI, MinIO, Elasticsearch, PostgreSQL et Redis.

Sommaire

- Introduction et objectifs
- Presentation des donnees
- Architecture generale
- Pipeline Airflow
- Zones Raw, Staging et Curated
- API Gateway
- Niveau avance et optimisations
- Resultats de verification
- Procedure de lancement
- Conclusion

Introduction et objectifs

Ce projet met en place un data lake de bout en bout sur le theme finance. Le choix du domaine financier est coherent avec les series temporelles du sujet: il permet de manipuler des donnees OHLCV, de calculer des indicateurs techniques, puis de detecter des comportements anormaux sur les marches.

L objectif technique est de couvrir la chaine complete: ingestion depuis deux sources, stockage brut, transformations vers des zones structurees, exposition par API Gateway, orchestration automatique et benchmark avance entre un endpoint standard et un endpoint optimise.

Perimetre retenu - Le theme est volontairement limite a la finance: aucune autre thematique n est melangee au projet.

Presentation des donnees

Le data lake combine deux sources de donnees financieres, conformement aux consignes du projet.

Source	Role	Format	Exemples
Dataset fichier local	Backdata historique et reproductible	CSV	finance_dataset.csv, principalement AAPL
API Yahoo Finance via yfinance	Actualisation quotidienne et batches a la demande	Donnees tabulaires OHLCV	AAPL, MSFT, GOOGL, indices ^GSPC, ^DJI, ^IXIC

Les champs exploites sont les prix Open, High, Low, Close, Adjusted Close, Volume, le ticker et la date. Ces champs sont adaptes aux calculs de moyennes mobiles, RSI, MACD, bandes de Bollinger, volatilité et rendement journalier.

Architecture generale

L architecture suit une logique medaillon Raw, Staging, Curated. Les composants sont conteneurises avec Docker Compose afin de garantir un demarrage reproductible.

Couche	Technologie	Justification
Raw	MinIO + Elasticsearch	MinIO conserve les fichiers bruts; Elasticsearch permet une recherche rapide dans les evenements OHLCV.
Staging	PostgreSQL	Donnees nettoyees et structurees avec indicateurs techniques.
Curated	PostgreSQL	Donnees enrichies par detection d anomalies et signaux de trading.
Orchestration	Apache Airflow	DAG planifie du lundi au vendredi a 6h UTC, avec reprise et logs.

Couche	Technologie	Justification
API Gateway	FastAPI	Endpoints /raw, /staging, /curated, /health, /stats, /ingest, /ingest_fast.
Cache	Redis	Cache optionnel pour accélérer /ingest_fast.

Pipeline Airflow

Le DAG principal se nomme `financial_data_lake_pipeline`. Il orchestre l'ensemble du flux de données financier.

1. `start`: point d'entrée du DAG.
2. `ingest_file` et `ingest_api`: ingestion parallèle depuis le dataset fichier et depuis yfinance.
3. `transform_staging`: consolidation en PostgreSQL avec calcul des indicateurs techniques.
4. `transform_curated`: enrichissement par Isolation Forest, scoring d'anomalies et classification.
5. `log_summary`: résumé de pipeline dans les logs Airflow.
6. `end`: fin contrôlée du workflow.

La planification est configurée sur `0 6 * * 1-5`, donc une exécution les jours ouvrables à 6h UTC. Le DAG utilise LocalExecutor, des retries et XCom pour propager les résultats entre tâches.

Zones du Data Lake

Raw

La zone Raw conserve les données les plus proches possible de la source. Les fichiers sont stockés dans MinIO et les lignes OHLCV sont indexées dans Elasticsearch.

- Bucket `raw-financial-data`: fichiers CSV par ticker et par date.
- Bucket `raw-api-data`: traces de données issues de l'API.
- Index `raw_financial_events`: recherche par ticker, date, source et valeurs OHLCV.

Staging

La zone Staging normalise les données en table `staging_ohlc`. Les données y deviennent directement exploitables par API et par traitements analytiques.

- Calculs: SMA 20/50, EMA 12/26, RSI 14, MACD, bandes de Bollinger.
- Mesures: `daily_return` et `volatility_20`.
- Gestion des doublons par `upsert ticker/date`.

Curated

La zone Curated contient les données finales. Elle ajoute des scores d'anomalie, des flags et des catégories utiles pour l'analyse financière.

- Modele: Isolation Forest sur rendement, volatilité, volume z-score et RSI.
- Sorties: anomaly_score, is_anomaly, anomaly_type et signal buy/sell/hold.
- Objectif: identifier des chocs, pics de volume et comportements atypiques.

API Gateway

FastAPI expose une interface unique pour interroger et alimenter le data lake sans acceder directement aux bases ou aux buckets.

Endpoint	Usage
GET /health	Etat des dependances: PostgreSQL, MinIO, Elasticsearch, Redis.
GET /stats	Volumes par couche et metriques de remplissage.
GET /raw	Recherche dans la zone Raw via Elasticsearch.
GET /staging	Lecture des donnees OHLCV enrichies par indicateurs.
GET /curated	Lecture des donnees finales avec anomalies et signaux.
POST /ingest	Pipeline synchrone standard, mesure de reference.
POST /ingest_fast	Pipeline optimise pour le niveau avance.

Niveau avance et optimisations

Le niveau avance demande un endpoint /ingest, un endpoint /ingest_fast et une amelioration d au moins 30% sur les memes tailles de batch. Le projet couvre ces points.

Optimisation	Implementation	Effet attendu
Parallelisation	ThreadPoolExecutor avec 8 workers	Telechargement yfinance et uploads MinIO plus rapides.
Vectorisation	NumPy et pandas rolling	Calculs techniques reduits sans boucles Python inutiles.
Bulk Elasticsearch	helpers.bulk	Moins d allers-retours reseau pour l indexation.
Batch PostgreSQL	execute_values	Insertion/upsert plus efficace que des requetes unitaires.
Cache Redis	TTL de 5 minutes si use_cache=true	Evite les telechargements repetes en test ou demo.

Resultats de verification

Les controles suivants ont ete executes apres relance de Docker Desktop et des services Docker Compose.

Controle	Resultat verifie
Services Docker	PostgreSQL, MinIO, Elasticsearch, Redis, Airflow et API lances; services critiques healthy.
API /health	overall=ok; PostgreSQL, MinIO, Elasticsearch et Redis OK.
Airflow /health	metadatabase healthy et scheduler healthy.
Import DAG	No data found, donc aucune erreur d import.
Tests unitaires	6 tests executes, 6 OK.
DAG manuel	codex_finalcheck_20260707T1734Z en success, 7 taches success.

Volumes apres relance

Zone	Volume verifie
Raw MinIO	533 objets au total: 421 raw-financial-data et 112 raw-api-data.
Raw Elasticsearch	5930 documents indexes.
Staging PostgreSQL	5899 lignes dans staging_ohlc.
Curated PostgreSQL	4891 lignes dans curated_analysis.
Logs ingestion	28 lignes dans ingestion_logs.

Benchmark avance

Batch	/ingest	/ingest_fast	Gain	Statut
1 ticker	4160.22 ms	1863.95 ms	55.20%	success, 0 erreur
100 tickers	70631.54 ms	23612.12 ms	66.57%	success, 0 erreur

Formule: gain = (temps standard - temps optimise) / temps standard x 100. Les deux mesures dépassent le seuil demande de 30%.

Procédure de lancement

1. Ouvrir Docker Desktop et attendre que le moteur Docker soit disponible.
2. Depuis le dossier du projet, lancer: `docker compose up -d --build`.
3. Verifier les services avec: `docker compose ps`.
4. Verifier l API: `http://localhost:8000/health` et la documentation: `http://localhost:8000/docs`.
5. Ouvrir Airflow: `http://localhost:8080` avec admin/admin, puis declencher le DAG `financial_data_lake_pipeline` si besoin.
6. Ouvrir MinIO: `http://localhost:9001` avec minioadmin/minioadmin.

Acces - Airflow utilise admin/admin. MinIO utilise minioadmin/minioadmin. Ces identifiants sont adaptes a un environnement local de projet.

Conclusion

Le projet repond aux exigences du sujet: deux sources de donnees, architecture Raw/Staging/Curated, pipeline Airflow planifie, API Gateway complete, endpoints avances et benchmark documente. La relance du 7 juillet 2026 confirme que les services, tests, DAG et volumes fonctionnent correctement.

Conclusion de validation - Le projet est operationnel et le niveau avance est valide par des gains superieurs a 30% sur batch 1 et batch 100.